

Distribuições contínuas

Variáveis aleatórias e leis de probabilidade.
Medidas de localização, dispersão e forma.
Distribuições univariadas mais comuns.
Pares aleatórios e vectores aleatórios.
Distribuição normal multivariada.

Variável aleatória e função de distribuição (revisão)

Seja (Ω, \mathcal{A}, P) um espaço de probabilidades.

Variável aleatória é uma função $X: \Omega \rightarrow \mathbb{R}$

tal que $X^{-1}(B) \in \mathcal{A}, \forall B \in \mathcal{B}$; então $P(X \in B) = P(X^{-1}(B))$


A **função de distribuição** (fd) de uma v.a. X é definida por

$$F(x) = P(X \leq x), x \in \mathbb{R}$$

Se o contradomínio de X for um conjunto infinito não numerável (e.g., um intervalo, \mathbb{R}^+ ou \mathbb{R}), a v.a. X é **não discreta**. Neste caso, se existir uma função $f: \mathbb{R} \rightarrow \mathbb{R}$ que desempenhe um papel análogo ao da fmp (chamada **função densidade de probabilidade**), a v.a. diz-se **absolutamente contínua**.

caso discreto

$$f(x) = \begin{cases} P(X = x) & , x \in \{x_1, x_2, \dots\} \\ 0 & , x \notin \{x_1, x_2, \dots\} \end{cases}$$




$$(i) \quad p_i \geq 0$$

$$(ii) \quad \sum_i p_i = 1 \quad \text{soma unitária}$$

$$(iii) \quad P(X \in B) = \sum_{i: x_i \in B} P(X = x_i)$$

caso absol. contínuo

$$f(x) = 0, \text{ se } x \notin \text{supp}(X)$$



$$(i) \quad f(x) \geq 0$$

$$(ii) \quad \int_{-\infty}^{+\infty} f(x) dx = 1 \quad \text{área unitária}$$

$$(iii) \quad P(X \in B) = \int_B f(x) dx$$

probabilidades são integrais (áreas)

fmp / fdp (massa de probabilidade / densidade de probabilidade)

As v.a.'s **discretas** são as que têm suporte contável, $\{x_1, x_2, x_3, \dots\}$. Ficam identificadas pela **fmp** (função massa de probabilidade).

fmp

$$p_i = f(x_i) = P(X = x_i)$$

tal que

$$p_i \geq 0; \sum_i p_i = 1$$

As v.a.'s **absolutamente contínuas** têm suporte infinito não numerável. Ficam identificadas por uma **fdp** (função densidade de probabilidade).

fdp

$$f: \mathbb{R} \rightarrow \mathbb{R} \\ x \mapsto f(x)$$

tal que

$$f(x) \geq 0; \int_{\mathbb{R}} f(x) dx = 1$$

Distribuições (absolutamente) contínuas

Uma v.a. X diz-se **absolutamente contínua** se existir uma fdp $f: \mathbb{R} \rightarrow \mathbb{R}$, tal que


$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

Então

$$F'(x) = f(x)$$

e

$$P(a < X \leq b) = \int_a^b f(x) dx = F(b) - F(a)$$



Recorde-se que uma v.a. X (discreta, contínua, ou outra) fica identificada pela **função de distribuição** (fd), $F(x) = P(X \leq x)$, $x \in \mathbb{R}$

As fd têm as seguintes propriedades, que as caracterizam:

são não decrescentes, contínuas à direita e $\lim_{x \rightarrow -\infty} F(x) = 0$, $\lim_{x \rightarrow +\infty} F(x) = 1$

- No caso discreto,

$$F(x) = \sum_{i: x_i \leq x} p_i$$



função em escada (saltos p_i nos pontos x_i)

- No caso contínuo,

$$F(x) = \int_{-\infty}^x f(y) dy$$



função contínua, $F'(x) = f(x)$

Em qualquer caso
(discreto, contínuo, ou outro)

$$P(a < X \leq b) = F(b) - F(a)$$

Variáveis aleatórias (absol.) contínuas

- Têm suporte infinito não numerável
- Ficam identificadas pela fdp $f: \mathbb{R} \rightarrow \mathbb{R}$ que satisfaz a

$$(i) \quad f(x) \geq 0$$

$$(ii) \quad \int_{-\infty}^{+\infty} f(x) dx = 1$$

$$(iii) \quad P(X \in B) = \int_B f(x) dx$$

O conhecimento da fdp equivale ao da fd pois
dada uma fdp f temos $F(x) = \int_{-\infty}^x f(y) dy$
e dada uma fd F temos $f(x) = F'(x)$

Notas:

1. O valor $f(x)$ da fdp não representa uma probabilidade (as probabilidades são integrais = áreas). De facto, $P(X = x) = \int_{\{x\}} f(t) dt = 0$
2. As fdp podem ter valores superiores a 1, e.g., fdp $f(x) = 2 I_{[0, 0.5]}(x)$ * e não têm que ser contínuas para todo o x (podem até não estar definidas em alguns pontos)
3. No caso contínuo (contrariamente ao caso discreto), tem-se
$$P(a < X \leq b) = P(a \leq X \leq b) = P(a \leq X < b) = P(a < X < b) = \int_a^b f(x) dx$$



* A função indicatriz do conjunto A é dada por
$$I_A(x) = \begin{cases} 1 & , se \ x \in A \\ 0 & , se \ x \notin A \end{cases}$$

Distribuições (absolutamente) contínuas

- distribuição uniforme num intervalo
- distribuição exponencial de parâmetro λ
durações de vida, intervalos de tempo entre ocorrências de fenómenos consecutivos (está relacionada com a Poisson)
- distribuição gama de parâmetros n e λ (generalização da exponencial)
intervalos de tempo entre a k -ésima e $k+n$ -ésima ocorrências
- distribuição normal (ou gaussiana)
fenómenos que resultam de causas aditivas

Distribuição uniforme (contínua) – $U[a,b]$

dunif, punif, ...




$$f(x) = \frac{1}{b-a}, \quad a < x < b$$

$$F(x) = \begin{cases} 0 & , \quad x < a \\ \frac{x-a}{b-a} & , \quad a \leq x < b \\ 1 & , \quad x \geq b \end{cases}$$


$$\mu = \frac{a+b}{2}, \quad \sigma^2 = \frac{(b-a)^2}{12}$$

Distribuição exponencial – $Exp(\lambda)$

dexp, pexp, ...



$$f(x) = \lambda e^{-\lambda x}, \quad x > 0$$




$$F(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$

$$\mu = \frac{1}{\lambda}, \quad \sigma^2 = \frac{1}{\lambda^2}$$

Nota: Esta distribuição “não tem memória”, i.e.,
 $P(X > t + y \mid X > t) = P(X > y)$, para $t > 0$, $y > 0$

Distribuição normal (ou gaussiana)

dnorm, pnorm, ...



Carl Friedrich Gauss
1777-1855

valor médio desvio padrão

$X \sim N(\mu, \sigma)$

$Z \sim N(0,1)$


$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}$$


$$X = \sigma Z + \mu$$

$$Z = (X - \mu) / \sigma$$

$$P(-1.96 < Z < 1.96) = 0.9500042 \\ \cong 0.95$$



$$P(-1 < Z < 1) = 0.6826895 \\ \cong 0.683$$



Exercício:


(a) Calcule $P(-2 < Z < 2)$, sendo $Z \sim N(0,1)$.

```
pnorm(2) - pnorm(-2)
```

```
[1] 0.9544997
```

(b) Calcule $P(\mu - 2\sigma < X < \mu + 2\sigma)$, sendo $X \sim N(\mu, \sigma)$.


Densidades normais com o mesmo valor médio e diferentes variâncias:



$$\sigma = 0 \quad \sigma = 2$$

σ é um parâmetro de dispersão

Densidades normais com diferentes valores médios e mesma variância:



$$\mu = 0 \quad \mu = 2$$

μ é um parâmetro de localização

Valor médio de uma v.a. X (contínua)

Valor médio (ou **valor esperado**) de uma v.a. X , contínua, é uma “média pesada” dos valores x que a v.a. pode assumir (os pesos são os valores $f(x)$) e representa-se por $E(X)$, μ ou μ_X . É dado por

$$\mu = E(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

desde que este integral convirja absolutamente, i.e., desde que $\int_{-\infty}^{+\infty} |x| f(x) dx < +\infty$

Nota: Há v.a.'s que não têm valor médio. Por exemplo, a v.a. $X \sim \text{Cauchy}(0,1)$, com fdp

$$f(x) = \frac{1}{\pi} \frac{1}{1+x^2}, -\infty < x < +\infty$$

pois

$$\int_{-\infty}^{+\infty} |x| \frac{1}{1+x^2} dx = +\infty$$

Exemplo 18: Cálculo do valor médio de uma v.a. $X \sim U[a,b]$

$$\mu = E(X) = \int_a^b x \frac{1}{b-a} dx = \frac{1}{b-a} \frac{x^2}{2} \Big|_a^b = \frac{1}{b-a} \frac{b^2 - a^2}{2} = \frac{b+a}{2}$$

(μ é o ponto médio do intervalo $[a,b]$ e o ponto de simetria da fdp)

Valor médio de $h(X)$, sendo X contínua

Dada uma função h , definimos analogamente o valor médio da v.a. $Y = h(X)$ por

$$E(h(X)) = \int_{-\infty}^{+\infty} h(x) f(x) dx$$

desde que este integral convirja absolutamente

Variância e desvio padrão de X

variância

$$\sigma^2 = \text{var}(X) = E((X - \mu)^2) = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$$

desvio padrão

$$\sigma = \sqrt{\text{var}(X)}$$

A **moda**, no caso contínuo, é o valor x tal que $f(x)$ é máximo; há distribuições unimodais, bimodais, plurimodais e amodais.

O **coeficiente de assimetria** é definido do mesmo modo que no caso discreto, i.e.,

$$\beta_1 = E((X - \mu)^3 / \sigma^3) = \frac{1}{\sigma^3} \int_{-\infty}^{+\infty} (x - \mu)^3 f(x) dx$$

As fórmulas e propriedades dadas sobre valores médios, variâncias, etc. para o caso discreto mantêm-se válidas para o caso contínuo. As demonstrações são análogas, substituindo os somatórios por integrais. Assim, temos por exemplo

$$\text{var}(X) \geq 0$$

$$E(a + bX) = a + bE(X)$$

$$\text{var}(X) = E(X^2) - \mu^2$$

$$\text{var}(a + bX) = b^2 \text{var}(X)$$

$$\sigma_{a+bX} = |b| \sigma_X$$

Exemplo 18 (cont.): Cálculo de $E(X^2)$ e da variância de $X \sim U[a,b]$

$$E(X^2) = \int_a^b x^2 \frac{1}{b-a} dx = \frac{1}{b-a} \frac{x^3}{3} \Big|_a^b = \frac{1}{b-a} \frac{b^3 - a^3}{3} = \frac{b^2 + ab + a^2}{3}$$

$$\begin{aligned} \text{var}(X) &= E(X^2) - E^2(X) = \frac{b^2 + ab + a^2}{3} - \frac{(b+a)^2}{4} = \\ &= \frac{b^2 + ab + a^2}{3} - \frac{b^2 + 2ab + a^2}{4} = \frac{b^2 - 2ab + a^2}{12} = \frac{(b-a)^2}{12} \end{aligned}$$

Exemplo 19: Cálculo do valor médio e variância de $X \sim \text{Exp}(\lambda)$

$$E(X) = \int_0^{+\infty} \lambda x e^{-\lambda x} dx = -x e^{-\lambda x} \Big|_0^{+\infty} - \int_0^{+\infty} -e^{-\lambda x} dx = 0 - \frac{1}{\lambda} e^{-\lambda x} \Big|_0^{+\infty} = \frac{1}{\lambda}$$

$$E(X^2) = \int_0^{+\infty} \lambda x^2 e^{-\lambda x} dx = -x^2 e^{-\lambda x} \Big|_0^{+\infty} - \int_0^{+\infty} -2x e^{-\lambda x} dx = 0 + \frac{2}{\lambda} \int_0^{+\infty} \lambda x e^{-\lambda x} dx = \frac{2}{\lambda} E(X) = \frac{2}{\lambda^2};$$

$$\text{var}(X) = E(X^2) - E^2(X) = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

Integração por partes:

$$\int h' g = h g - \int h g'$$

Características teóricas (medidas de localização, dispersão e forma)

nome	símbolo	caso discreto	caso contínuo
valor médio* $E(X)$	μ	$\sum_i x_i p_i$	$\int_{-\infty}^{+\infty} x f(x) dx$
variância* $\text{var}(X) = E((X - \mu)^2)$	σ^2	$\sum_i (x_i - \mu)^2 p_i$	$\int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$
coef. assim.* $E((X - \mu)^3 / \sigma^3)$	β_1	$\frac{1}{\sigma^3} \sum_i (x_i - \mu)^3 p_i$	$\frac{1}{\sigma^3} \int_{-\infty}^{+\infty} (x - \mu)^3 f(x) dx$
mediana ⋮	$\chi_{1/2}$	$\inf\{x : F(x) \geq 1/2\}$	



* existem somente se as séries/integrais convergirem absolutamente

Exemplo 20: Cálculo do valor médio e variância de $Z \sim N(0,1)$

$$\begin{aligned} E(Z) &= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} x e^{-x^2/2} dx = -\frac{1}{\sqrt{2\pi}} e^{-x^2/2} \Big|_{-\infty}^{+\infty} = 0 \\ \text{var}(Z) &= E(Z^2) = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} x^2 e^{-x^2/2} dx = \\ &= -\frac{1}{\sqrt{2\pi}} x e^{-x^2/2} \Big|_{-\infty}^{+\infty} - \int_{-\infty}^{+\infty} -\frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = 0 + 1 = 1 \end{aligned}$$

Quantil- p (caso contínuo)

É o valor de x que corresponde à área acumulada p (à esquerda de x no gráfico da fdp) e representa-se por χ_p . No caso $p = 0.5$ temos a **mediana**



Exercício: Calcule a mediana da distribuição $Exp(1)$

$$\chi_{0.5} = F^{-1}(0.5)$$

```
qexp(1/2, 1)
[1] 0.6931472
log(2)
[1] 0.6931472
```

Exemplo 19 (cont.): Cálculo da mediana de $X \sim Exp(\lambda)$, que é a solução da equação $F(x)=1/2$, sendo $F(x) = 1 - e^{-\lambda x}$, $x > 0$.

$$F(x) = 1 - e^{-\lambda x} = \frac{1}{2} \Leftrightarrow e^{-\lambda x} = \frac{1}{2} \Leftrightarrow -\lambda x = -\log(2) \Leftrightarrow x = \frac{\log(2)}{\lambda}$$

Note-se que nesta distribuição temos $\chi_{0.5} = \frac{\log(2)}{\lambda} < \frac{1}{\lambda}$

quantil- p de uma v.a. X


Mais geralmente, o **quantil- p** de uma v.a. X contínua (ou da sua distribuição) é o valor x que corresponde a uma probabilidade p acumulada à sua esquerda. Se a fd F for estritamente crescente, coincide com a inversa da fd no ponto p , i.e., com $F^{-1}(p)$.

Inclui os casos particulares da

mediana,	se $p = 1/2$
quartis,	se $p = 1/4, 1/2, 3/4$ (1º, 2º e 3º quantil)
decis,	se $p = i/10$, com $i = 1, 2, \dots, 9$ (1º, 2º, ..., 9º decil)
percentis,	se $p = i/100$, com $i = 1, 2, \dots, 99$ (1º, 2º, ..., 99º percentil)

Exercício: Calcule os quartis, o 3º decil e os quantis de probabilidade $i/6$, da distribuição

```
Exp(1)  qexp(1:3/4,1)
[1] 0.2876821 0.6931472 1.3862944
qexp(3/10,1)
[1] 0.3566749
qexp(1:5/6,1)
[1] 0.1823216 0.4054651 0.6931472
[4] 1.0986123 1.7917595
```



Exemplo 19 (cont.): Cálculo do quantil- p de $X \sim \text{Exp}(\lambda)$, que é a solução da equação $F(x) = p$, com $F(x) = 1 - e^{-\lambda x}$, $x > 0$.

$$p = F(x) = 1 - e^{-\lambda x} \Leftrightarrow e^{-\lambda x} = 1 - p \Leftrightarrow -\lambda x = \log(1 - p) \Leftrightarrow x = -\frac{\log(1 - p)}{\lambda}$$

Logo $\chi_p = -\frac{\log(1 - p)}{\lambda}$

Exercício: Calcule os decis da distribuição $N(0,1)$

```
qnorm(1:9/10)
```

```
[1] -1.2815516 -0.8416212 -0.5244005 -0.2533471  0.0000000  0.2533471  
[7]  0.5244005  0.8416212  1.2815516
```

São simétricos porque a distribuição é simétrica

se	$p = 1/2$	o quantil chama-se	mediana
	$p = 1/4, 2/4, 3/4$		quartil
	$p = 1/10, \dots, 9/10$		decil
	$p = 1/100, \dots, 99/100$		percentil

Quantil de probabilidade p

No caso geral, dada uma fd $F(\cdot)$ qualquer (discreta, contínua ou outra), o **quantil de probabilidade p** , representado por χ_p , é definido por


$$\chi_p = \inf\{x : F(x) \geq p\}$$

Esta “função quantil” definida para uma fd qualquer F é também conhecida por “**inversa generalizada**” de F (e denotada por F^{\leftarrow})



Quantil de probabilidade p (notação: χ_p)

$$\chi_p = \inf\{x : F(x) \geq p\}$$

Caso discreto (fd F):




Caso contínuo (f.d. F e fdp f):




Notas:

1. Se X (com valor médio μ) for simétrica* em torno do ponto a , e unimodal, então $\mu = \chi_{0.5} = moda = a$
2. A assimetria de uma distribuição unimodal está relacionada com a posição relativa das seguintes 3 medidas de localização: valor médio (μ), mediana ($\chi_{0.5}$) e moda. Em geral uma assimetria positiva ($\beta_1 > 0$) corresponde à relação $moda < \chi_{0.5} < \mu$; e assimetria negativa, a $\mu < \chi_{0.5} < moda$

Assimetria positiva




Assimetria negativa



* uma v.a. com fd F diz-se **simétrica em torno do ponto a** se $F(a-x) = 1 - F(a+x)$
- no caso contínuo, equivale a ter simetria da fdp em torno de a , i.e., $f(a-x) = f(a+x)$

Nota: Há v.a.'s X que **não são discretas nem contínuas**, e que têm interesse. Por exemplo, para modelar o **tempo de espera num semáforo**, a **duração de uma anestesia**, a **quantidade de precipitação em dado local em certo mês do ano**, etc.. A f.d. de X nestes 3 exemplos é uma **mistura de uma v.a. discreta** com suporte $\{0\}$ (pois o “tempo de espera no semáforo”, a “duração da anestesia” ou a “precipitação” pode ser 0, com certa probabilidade p) **com uma v.a. contínua** positiva (pois com probabilidade $1 - p$ esse “tempo de espera no semáforo”, etc., será positivo). Assim, a f.d. de X tem um salto de amplitude p no ponto 0 e é contínua em $\mathbb{R} - \{0\}$. Um exemplo concreto é a seguinte f.d.:

$$F(x) = \begin{cases} 0 & , x < 0 \\ 1 - (1 - p)e^{-\lambda x} & , x \geq 0 \end{cases}$$



Uma mistura de uma v.a. discreta com uma v.a. contínua (com fd's F_d e F_c , respetivamente) tem fd da forma $F(x) = p F_d(x) + (1 - p) F_c(x)$

Distribuições contínuas – formulário

modelo	parâmetros	v. médio μ	variância σ^2	mediana $\chi_{1/2}$	assimetria β_1
$U[a, b]$	$a < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{a+b}{2}$	0
$Exp(\lambda)$	$\lambda > 0$	$1/\lambda$	$1/\lambda^2$	$\frac{\log 2}{\lambda}$	2
$N(\mu, \sigma)$	$\mu \in \mathbb{R}$ $\sigma > 0$	μ	σ^2	μ	0

Mantêm-se, para v.a.'s contínuas, as mesmas propriedades que eram válidas no caso discreto (vd. slide 136):

$$\text{var}(X) \geq 0$$

$$\text{var}(X) = E(X^2) - \mu^2$$

$$E(a + bX) = a + bE(X)$$

$$\text{var}(a + bX) = b^2 \text{var}(X)$$

Exercício:

- a) Deduza a fórmula da fdp de $Y = a + bX$, à custa da fdp de X
- b) Recorde que o valor médio e o desvio padrão de $Z \sim N(0,1)$ são 0 e 1 (vd. exemplo 20, slide 139). Prove que $E(X) = \mu$ e $\text{var}(X) = \sigma^2$, no caso $X \sim N(\mu, \sigma)$.
- c) Dada uma v.a. X com valor médio μ e desvio padrão σ , calcule o valor médio e o desvio padrão da v.a. padrão (ou standard), $Y = (X - \mu) / \sigma$

Resolução:

a) Dedução da fórmula da fdp de $Y = a + b X$, à custa da fdp de X :

$$F_Y(y) = P(a + bX \leq y) = P(bX \leq y - a) = \begin{cases} P(X \leq \frac{y-a}{b}) = F_X(\frac{y-a}{b}) & , b > 0 \\ P(X \geq \frac{y-a}{b}) = 1 - F_X(\frac{y-a}{b}) & , b < 0 \end{cases}$$

$$\Rightarrow f_Y(y) = \begin{cases} \frac{d}{dy} F_X(\frac{y-a}{b}) = f_X(\frac{y-a}{b}) \frac{1}{b} & , b > 0 \\ -\frac{d}{dy} F_X(\frac{y-a}{b}) = f_X(\frac{y-a}{b}) \frac{1}{-b} & , b < 0 \end{cases} \quad \text{Logo} \quad f_Y(y) = \frac{1}{|b|} f_X(\frac{y-a}{b})$$

b) $E(Z) = 0$ e $\text{var}(Z) = 1$. Prova-se que $E(X) = \mu$ e $\text{var}(X) = \sigma^2$, no caso $X \sim N(\mu, \sigma)$.

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} = \frac{1}{\sigma} f_Z\left(\frac{x-\mu}{\sigma}\right) \quad \text{portanto } X = \mu + \sigma Z$$

$$\text{Logo} \quad E(X) = E(\mu + \sigma Z) = \mu + \sigma E(Z) = \mu \quad \text{e}$$

$$\text{var}(X) = \text{var}(\mu + \sigma Z) = \sigma^2 \text{var}(Z) = \sigma^2$$

Vector aleatório

É uma função $(X_1, \dots, X_k) : \Omega \rightarrow \mathbb{R}^k$, que a cada $\omega \in \Omega$ faz corresponder $(X_1(\omega), \dots, X_k(\omega))$ tal que ...

- fmp conjunta (**c. discreto**) / fdp conjunta (**c. contínuo**);
- fd conjunta: $F(x_1, \dots, x_k) = P(X_1 \leq x_1, \dots, X_k \leq x_k)$

X_1, \dots, X_k dizem-se **mutuamente independentes** se

$\forall B_1 \subset \mathbb{R}, \dots, B_k \subset \mathbb{R}$ borelianos de \mathbb{R}

$$P(X_1 \in B_1, \dots, X_k \in B_k) = P(X_1 \in B_1) \dots P(X_k \in B_k)$$



as fmp/fdp conjuntas fatorizam-se no produto das fmp/fdp marginais

Par aleatório

É uma função $(X, Y) : \Omega \rightarrow \mathbb{R}^2$, que a cada $\omega \in \Omega$ faz corresponder um par $(X(\omega), Y(\omega))$ tal que ...

O par diz-se **absolutamente contínuo** se existir uma função não negativa $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ (chamada **fdp conjunta**) e com integral unitário, tal que

$$F(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^x \left(\int_{-\infty}^y f(u, v) dv \right) du$$

Recorde-se que as v.a.'s X e Y se dizem **independentes** se para quaisquer borelianos A e B de \mathbb{R} ,

$$P(X \in A, Y \in B) = P(X \in A) P(Y \in B)$$

No caso contínuo, equivale a ter

$$f(x, y) = f_X(x) f_Y(y)$$

Pares aleatórios contínuos


fdp conjunta: $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ tal que $f(x, y) \geq 0$ e $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$

fd conjunta: $F(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^x \left(\int_{-\infty}^y f(u, v) dv \right) du$

Então

$$\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y)$$

$$\begin{aligned} P(a < X \leq b, c < Y \leq d) &= \int_a^b \int_c^d f(x, y) dx dy = \\ &= F(b, d) - F(a, d) - F(b, c) + F(a, c) \end{aligned}$$



Distribuições marginais e condicionais

Analogamente ao caso discreto, as fdp marginais de X e de Y e as fdp condicionais de X e de Y são as seguintes

fdp marginais: (i) de X :

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy$$

(ii) de Y :

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx$$

fdp condicionais: (i) de X , dado $\{Y = y\}$:

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

(ii) de Y , dado $\{X = x\}$:

$$f_{Y|X=x}(y) = \frac{f_{X,Y}(x, y)}{f_X(x)}$$

A independência entre X e Y equivale a ter $f_{X,Y}(x, y) = f_X(x)f_Y(y)$

Nota:


Se for possível factorizar a fdp conjunta $f(x,y)$ na forma $f(x,y) = g(x) h(y)$, $(x,y) \in \mathbb{R}^2$ então temos que g e h , a menos de constantes multiplicativas, são as fdp's marginais de X e Y . De facto,

$$f_X(x) = \int_{-\infty}^{+\infty} f(x,y)dy = \int_{-\infty}^{+\infty} g(x)h(y)dy = g(x) \int_{-\infty}^{+\infty} h(y)dy = c_1 g(x)$$

e analogamente

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x,y)dx = \int_{-\infty}^{+\infty} g(x)h(y)dx = h(y) \int_{-\infty}^{+\infty} g(x)dx = c_2 h(y)$$

Exemplo 21: fdp conjunta de um par aleatório (X,Y) com distribuição uniforme no quadrado $[0,1] \times [0,1]$, i.e., com fdp conjunta



$$f(x, y) = I_{[0,1] \times [0,1]}(x, y)$$

ou

$$f(x, y) = \begin{cases} 1 & , 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & , c.c. \end{cases}$$

X e Y são independentes pois a fdp conjunta é o produto de duas fdp $U[0,1]$, dadas por $g(x) = I_{[0,1]}(x)$. De facto, para $(x,y) \in \mathbb{R}^2$ temos $f(x, y) = g(x)g(y)$

Valores médios* (caso contínuo)

v.a. X :

$$E(h(X)) = \int_{-\infty}^{+\infty} h(x) f(x) dx$$

par (X, Y) :

$$E(h(X, Y)) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} h(x, y) f(x, y) dx dy$$

Tal como no caso discreto, a **covariância** entre X e Y é definida por

$$\text{cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y)) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x - \mu_X)(y - \mu_Y) f(x, y) dx dy$$

e prova-se que $\text{cov}(X, Y) = E(XY) - E(X)E(Y)$


* existem somente se os integrais convergirem absolutamente

Exemplo 22: (X, Y) com fdp conjunta

$$f(x, y) = \begin{cases} 3x & , 0 \leq 2x \leq y \leq 2 \\ 0 & , \text{c.c.} \end{cases}$$

X e Y não são independentes pois $P(X > 0.5, Y < 1) = 0$ mas $P(X > 0.5)$ e $P(Y < 1)$ são positivas.

Cálculo das fdp's marginais:



$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy = \int_{2x}^2 3x dy = 3xy \Big|_{2x}^2 = 3x(2 - 2x) = 6x(1 - x), \quad 0 < x < 1$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx = \int_0^{y/2} 3x dx = \frac{3}{2} x^2 \Big|_0^{y/2} = \frac{3}{2} \frac{1}{4} y^2 = \frac{3}{8} y^2, \quad 0 < y < 2$$

Exemplo 22 (cont.): Cálculo de valores médios e covariância:

$$E(X) = \int_{-\infty}^{+\infty} x f_X(x) dx = \int_0^1 6x^2(1-x) dx = \int_0^1 6x^2 - 6x^3 dx = \left(2x^3 - \frac{6}{4}x^4\right) \Big|_0^1 = \frac{1}{2}$$

$$E(Y) = \int_{-\infty}^{+\infty} y f_Y(y) dy = \int_0^2 \frac{3}{8} y^3 dy = \frac{3}{8} \frac{1}{4} y^4 \Big|_0^2 = \frac{3}{8} \frac{16}{4} = \frac{3}{2}$$

$$\begin{aligned} E(XY) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xy f(x, y) dx dy = \int_0^1 \left(\int_{2x}^2 3x^2 y dy \right) dx = 3 \int_0^1 \frac{1}{2} x^2 y^2 \Big|_{2x}^2 dx = \\ &= 3 \int_0^1 \frac{1}{2} x^2 (4 - 4x^2) dx = 3 \int_0^1 2x^2 - 2x^4 dx = \frac{6}{3} x^3 - \frac{6}{5} x^5 \Big|_0^1 = 2 - \frac{6}{5} = \frac{4}{5} \end{aligned}$$

$$\text{cov}(X, Y) = E(XY) - E(X)E(Y) = \frac{4}{5} - \frac{1}{2} \frac{3}{2} = \frac{1}{20}$$

Valores médios, variâncias, etc. (resumo) *

v.a. X

$$E(h(X)) = \begin{cases} \sum_i h(x_i) p_i & \text{no c. discreto} \\ \int_{-\infty}^{+\infty} h(x) f(x) dx & \text{no c. contínuo} \end{cases}$$

par (X, Y)

$$E(h(X, Y)) = \begin{cases} \sum_i \sum_j h(x_i, y_j) p_{ij} & \text{no c. discreto} \\ \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} h(x, y) f(x, y) dx dy & \text{no c. contínuo} \end{cases}$$

Em particular – valores médios, variâncias, covariância e correlação:

$$\mu_X = E(X), \quad \mu_Y = E(Y), \quad \sigma_X^2 = \text{var}(X), \quad \sigma_Y^2 = \text{var}(Y)$$

$$\text{cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y)) ; \quad \rho(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

$$\text{cov}(X, Y) = E(XY) - E(X)E(Y)$$

* existem somente se as séries/integrais convergirem absolutamente

Propriedades (v.a.'s quaisquer)

São válidas as propriedades 1.1 a 4.6 (slides 92 a 98). Em particular,

- $E(a + bX) = a + bE(X)$
- $\text{var}(a + bX) = b^2 \text{var}(X)$
- $E(X_1 + \dots + X_n) = E(X_1) + \dots + E(X_n)$
- $\text{var}(X_1 + \dots + X_n) = \sum_i \text{var}(X_i) + 2 \sum_{i < j} \text{cov}(X_i, X_j)$

Se X_1, \dots, X_n independentes, então $\text{cov}(X_i, X_j) = 0$ e

- $\text{var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{var}(X_i)$
- $E(X_1 \dots X_n) = E(X_1) \dots E(X_n)$

- $\text{cov}(aX + bY, cU + dV) = ac \text{cov}(X, U) + ad \text{cov}(X, V) + bc \text{cov}(Y, U) + bd \text{cov}(Y, V)$
(bilinearidade)

Coeficiente de correlação entre duas v.a.'s (revisão)

Recorde-se que a correlação entre X e Y se define por

$$\rho = \rho(X, Y) = E\left(\frac{X - \mu_X}{\sigma_X} \frac{Y - \mu_Y}{\sigma_Y}\right) \quad \text{ou seja} \quad \rho = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

(caso exista este valor médio) e satisfaz a

- $-1 \leq \rho \leq 1$
- X e Y independentes $\Rightarrow \rho = 0$ (a recíproca não é verdadeira)
- $\rho = \pm 1 \Leftrightarrow P(Y = a + bX) = 1$ para algum $a \in \mathbb{R}$ e $b \neq 0$
- é invariante para transformações lineares de X e de Y
(a menos do sinal)

ρ mede a
relação de
linearidade
entre X e Y

Propriedades (v.a.'s normais)

Propriedades a demonstrar adiante
usando transformadas de Laplace

Se $X_i \sim N(\mu_i, \sigma_i)$ independentes, $i = 1, 2, \dots, n$, então

$$S_n \sim N\left(\sum \mu_i, \sqrt{\sum \sigma_i^2}\right)$$

$$\sum_{i=1}^n a_i X_i \sim N\left(\sum a_i \mu_i, \sqrt{\sum a_i^2 \sigma_i^2}\right)$$

Soma de v.a.'s

$$S_n = \sum_{i=1}^n X_i$$

Média de v.a.'s

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Em particular, se $X_i \sim N(\mu, \sigma)$ independentes, então


$$S_n \sim N(n\mu, \sigma\sqrt{n})$$

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$


Distribuição normal bivariada (ou gaussiana bivariada ou binormal)

com parâmetros $\mu, \mu', \sigma, \sigma', \rho$

gráficos das fdp's conjuntas
($\mu = \mu' = 0, \sigma = \sigma' = 1$)





$$\rho = 0$$



$$\rho = 0.8$$

e curvas de nível
($\mu = \mu' = 0, \sigma = \sigma' = 1$)



A fdp conjunta de um par (X,Y) binormal com parâmetros $\mu, \mu', \sigma, \sigma', \rho$ (que representam os valores médios e desvios padrões de X e Y e a correlação entre X e Y) é dada por

$$f(x, y) = \frac{1}{2\pi\sigma\sigma'\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}(x'^2 - 2\rho x' y' + y'^2)\right\}, \text{ com } \begin{cases} x' = \frac{x-\mu}{\sigma} \\ y' = \frac{y-\mu'}{\sigma'} \end{cases}$$

Neste modelo temos:

- (i) $X \sim N(\mu, \sigma)$ e $Y \sim N(\mu', \sigma')$
- (ii) $\rho = 0 \iff X$ e Y independentes
- (iii) Qualquer transformação linear do par é também binormal

Nota: o caso $\rho^2 = 1$ corresponde a uma distribuição concentrada numa recta, $y = a + b x$ (com $b \neq 0$), pelo que o suporte do par é uma recta (subconjunto unidimensional de \mathbb{R}^2 , dito degenerado a duas dimensões). A distribuição diz-se bivariada singular ou degenerada a duas dimensões

(i) Cálculo da fdp marginal de X , no caso (X,Y) binormal com parâmetros $\mu, \mu', \sigma, \sigma', \rho$

$$f(x, y) = \frac{1}{2\pi\sigma\sigma'\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)} \underbrace{(x'^2 - 2\rho x' y' + y'^2)}_{(1-\rho^2)x'^2 + \rho^2 x'^2 - 2\rho x' y' + y'^2}\right\}$$

$$\begin{aligned} & (1-\rho^2)x'^2 + \rho^2 x'^2 - 2\rho x' y' + y'^2 \\ & (1-\rho^2)x'^2 + (y' - \rho x')^2 \\ & (1-\rho^2)x'^2 + \left(y - [\mu' + \rho \frac{\sigma'}{\sigma}(x - \mu)]\right)^2 / \sigma'^2 \end{aligned} \quad \begin{cases} x' = \frac{x-\mu}{\sigma} \\ y' = \frac{y-\mu'}{\sigma'} \end{cases}$$

$$f(x, y) = \underbrace{\frac{1}{\sigma\sqrt{2\pi}} e^{-x'^2/2}}_{\text{fdp } N(\mu, \sigma)} \underbrace{\frac{1}{\sigma'\sqrt{2\pi}\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)\sigma'^2} \left(y - [\mu' + \rho \frac{\sigma'}{\sigma}(x - \mu)]\right)^2}}_{\text{fdp } N\left(\mu' + \rho \frac{\sigma'}{\sigma}(x - \mu), \sigma'\sqrt{1-\rho^2}\right)} \Rightarrow f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy =$$

$$= \frac{1}{\sigma\sqrt{2\pi}} e^{-x'^2/2}$$

$$\therefore X \sim N(\mu, \sigma)$$

Simulação de par aleatório binormal ($\mu = 1, \mu' = 2, \sigma = 2, \sigma' = 3, \rho = 0.8$)

package

mvtnorm

função

rmvnorm(n=..., mean=c(..., ...), sigma=...)


nº simulações

μ μ'

matriz de
covariâncias

$$\begin{pmatrix} \sigma^2 & \text{cov} \\ \text{cov} & \sigma'^2 \end{pmatrix}$$

```
library(dmvnorm)
sig <- matrix(c(4,4.8,4.8,9), ncol=2)
x <- rmvnorm(1000, c(1,2), sig)
colMeans(x)
[1] 0.9991239 1.9673403
var(x)
     3.797903 4.600176
     4.600176 8.823428
cor(x)
     1.0000000 0.7946646
     0.7946646 1.0000000
plot(x, xlab="x", ylab="y", las=1)
abline(h=2, col=4, lty=2)
abline(v=1, col=4, lty=2)
```



$$\begin{pmatrix} 4 & 4.8 \\ 4.8 & 9 \end{pmatrix}$$

$$\rho = \frac{4.8}{2 \times 3} = 0.8$$

Exercício: Qual a distribuição de $X - Y$ no caso (X, Y) binormal?

Resolução: Como qualquer transformação linear de um par binormal é também binormal, temos (atendendo a que as marginais de um par binormal são normais) que $X - Y$ é normal.

Falta apenas identificar os parâmetros, ou seja, calcular o valor médio e a variância de $X - Y$.

$$E(X - Y) = E(X) - E(Y) = \mu - \mu'$$

$$\text{var}(X - Y) = \text{var}(X) + \text{var}(Y) - 2 \text{cov}(X, Y) = \sigma^2 + \sigma'^2 - 2\rho\sigma\sigma'$$

Conclui-se que $X - Y$ tem distribuição $N(\mu - \mu', \tau)$, $\tau^2 = \sigma^2 + \sigma'^2 - 2\rho\sigma\sigma'$

Processo de Poisson

É um processo de chegadas ao longo do tempo ($t \geq 0$).

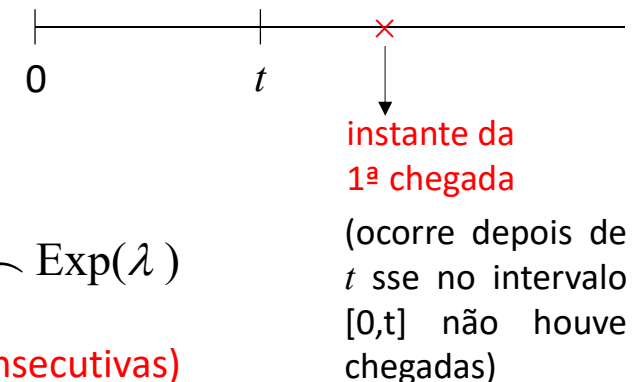
N_t = “nº de chegadas no intervalo $] 0, t]$ ”, tal que $N_0 = 0$ e $N_t \sim \text{Poisson}(\lambda t)$, sendo λ a **taxa** ou **intensidade** do processo (é o nº médio de chegadas numa unidade de tempo). Este processo, representado por $\{N_t\}_{t \geq 0}$ tem

- **incrementos independentes**, i.e., os números de chegadas em intervalos de tempo disjuntos são mutuamente independentes
- **incrementos estacionários**, i.e., em intervalos de tempo de igual amplitude, a distribuição dos números de chegadas é a mesma

Seja T o instante (aleatório) da primeira chegada. Então temos $T > t$ sse não houver chegadas no intervalo $] 0, t]$, donde

$$P(T > t) = P(N_t = 0) = e^{-\lambda t}, \text{ para } t > 0 \Rightarrow T \sim \text{Exp}(\lambda)$$

(fórmula também válida para os intervalos de tempo entre chegadas consecutivas)




Exercício: (i) Simule um processo de chegadas com intervalos de tempo (entre chegadas consecutivas) $Exp(\lambda)$, independentes, $\lambda=1/5$, no intervalo $[0,100]$. Represente graficamente a trajectória do processo.

(ii) Para $t = 25$, estime a distribuição de $N(t) = \text{“nº de chegadas até ao instante } t \text{”}$, por meio de simulação (com 100 mil réplicas).


Resolução: (i) Temos $E(X) = 1/\lambda$, se $X \sim Exp(\lambda)$

```
# em média há 100/5=20 chegadas em [0,100];  
# simulam-se 40 intervalos de tempo Exp(1/5):  
tps <- rexp(40,1/5)  
# nº de chegadas até t=100:  
fim <- min(which(cumsum(tps)>100))-1  
# gráfico da trajectória do processo:  
plot(cumsum(tps[1:fim]),1:fim,type="s",  
      xlim=c(0,100),xlab="t",ylab="N(t)",las=1)  
# acrescentando uma grelha:  
grid()
```



Resolução: (ii)

Para $t = 25$, simulam-se 10^5 valores de $N(t)$ = “nº de chegadas até ao instante t ” e elabora-se a correspondente tabela de frequências relativas dos valores obtidos.



```
# 1) recorrendo a matriz 50x10^5 de interv.tp
simul <- matrix(rexp(50*10^5,1/5),nr=50)
n.25 <- apply(simul,2,function(x) min(which(cumsum(x)>25))-1 )
plot(table(n.25)/100000,xlab="nº chegadas até t=25",ylab="freq. relativa")
table(n.25)/100000
      0      1      2      3      4      5      6      7      8      9     10 ...
0.00701 0.03388 0.08331 0.14005 0.17556 0.17673 0.14573 0.10299 0.06648 0.03573 0.01801 ...
round(dpois(0:20,1/5*25),5)
[1] 0.00674 0.03369 0.08422 0.14037 0.17547 0.17547 0.14622 0.10444 0.06528 0.03627 0.01813 ...

# 2) recorrendo a um ciclo for ...
```

Resolução: (ii)

```
# 2) recorrendo a um ciclo for
```

```
n.25 <- 0
```

```
for (i in 1:100000)
```

```
{ t <- 0; n <- 0;
```

```
  while(t<25)
```

```
    {t <- t+rexp(1,1/5); n <- n+1} ;
```

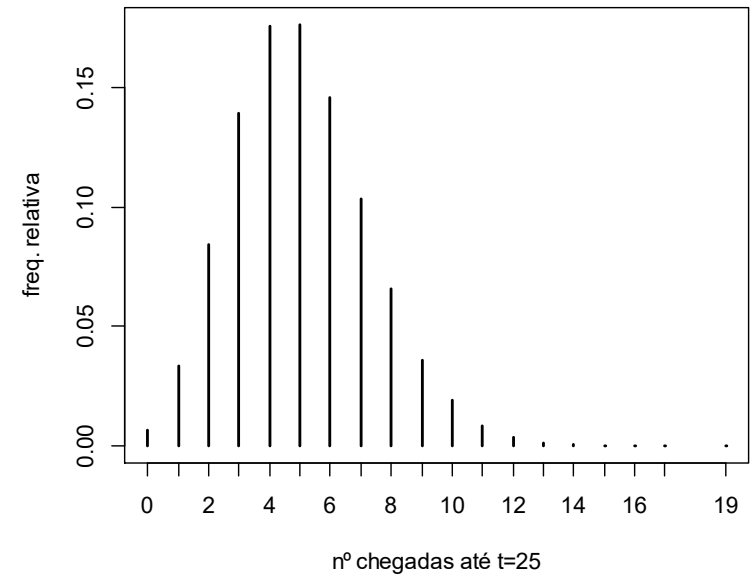
```
    n.25[i] <- n-1 }
```

```
table(n.25)/100000
```

0	1	2	3	4	5	6	7	8	9
0.00660	0.03345	0.08455	0.13954	0.17601	0.17642	0.14590	0.10344	0.06600	0.03584
10	11	12	13	14	15	16	17	19	
0.01895	0.00819	0.00331	0.00117	0.00041	0.00013	0.00006	0.00002	0.00001	

```
round(dpois(0:19,1/5*25),5)
```

0.00674	0.03369	0.08422	0.14037	0.17547	0.17547	0.14622	0.10444	0.06528	0.03627
0.01813	0.00824	0.00343	0.00132	0.00047	0.00016	0.00005	0.00001	0.00000	0.00000



Exercício: (i) Calcule a distribuição de $Y = Z^2$ no caso $Z \sim N(0,1)$.

(ii) Por meio de simulação, tente descobrir qual a distribuição da soma de duas v.a.'s independentes Y_1 e Y_2 (sendo $Y_i = Z_i^2$).

Resolução: (i) Representa-se usualmente a fd [fdp] de Z pela letra Φ [ϕ].

Para $y > 0$ temos

$$F_Y(y) = P(Y \leq y) = (Z^2 \leq y) = P(-\sqrt{y} \leq Z \leq \sqrt{y}) = \Phi(\sqrt{y}) - \Phi(-\sqrt{y})$$

donde

$$\begin{aligned} f_Y(y) &= \frac{d}{dy} F_Y(y) = \frac{d}{dy} \Phi(\sqrt{y}) - \frac{d}{dy} \Phi(-\sqrt{y}) = \phi(\sqrt{y}) \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \frac{1}{2\sqrt{y}} = \\ &= \phi(\sqrt{y}) \frac{1}{\sqrt{y}} = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{y}} e^{-y/2}, \quad y > 0 \end{aligned}$$

Exercício: (ii) Por meio de simulação, tente descobrir qual a distribuição da soma de duas v.a.'s independentes Y_1 e Y_2 , com a mesma distribuição de $Y = Z^2$ (diz-se que Y_1 e Y_2 são **independentes e identicamente distribuídas (i.i.d.)** com Y).

Resolução: (ii)

```
# simular 2 amostras de 10^6 valores N(0,1)
x <- rnorm(10^6)
y <- rnorm(10^6)
# amostra da soma dos seus quadrados
t <- x^2 + y^2
# histograma de área unitária:
hist(t,50,freq=F, main="")
# parece uma fdp exponencial com f(0)≈0.5
# sobrepor gráfico da fdp Exp(1/2)
curve(dexp(x,1/2),0,30,add=T,col=2)
# ou o histograma num único comando:
hist(rnorm(10^6)^2+rnorm(10^6)^2,50,freq=F,main="",xlab="t",ylab="freq / fdp")
```

